


Deteccion de Anomalias con LSTM-Autoencoder

Modelo no supervisado que aprende lo normal para detectar lo anormal — sin datos etiquetados.



Como detectar algo anormal cuando no tienes ejemplos de ello?

Banca

Transacciones
fradulentas
son escasas

Manufactura

Fallas de
maquina son
imprevisibles

Tecnologia

Caidas de
servidor son
poco frecuentes

En todos los casos: casi no hay ejemplos del problema para entrenar un modelo tradicional.

Aprende lo normal. Detecta lo que no lo es.

Un detector de incendios no sabe que es el fuego — solo sabe como huele el aire normal. Cuando el olor cambia demasiado, suena la alarma. Este modelo funciona igual.

1

Entrenamiento

Aprende el patron normal con datos historicos

2

Reconstruccion

Intenta reproducir cada nuevo dato que recibe

3

Deteccion

Si falla al reproducirlo lo marca como ANOMALIA

Numenta Anomaly Benchmark (NAB)

Dataset publico disenado para evaluar modelos de deteccion de anomalias en series temporales.

ENTRENAMIENTO

art_daily_small_noise.csv

Serie sin anomalias.
El modelo aprende
el patron normal.

EVALUACION

art_daily_jumpsup.csv

Serie con saltos abruptos.
El modelo nunca la vio.
Mide si detecta las anomalias.

Pipeline (secuencia de pasos que siguen los datos de inicio a fin):

Carga datos

Normalizacion

Ventanas (288)

Entrenamiento

Umbral MAE

Deteccion

El modelo detecto la anomalia sin haberla visto antes.



El error de reconstruccion supero el umbral exactamente en la zona anomala.

Funciona

El modelo detecto la anomalia correctamente sin haber visto ejemplos de ella durante el entrenamiento.

Aplica a industria real

El enfoque es valido para banca, manufactura, salud y tecnologia donde los datos anomalos son escasos.

Escalable

Con datos reales el siguiente paso es ajustar el umbral dinamicamente y conectarlo a un sistema de alertas.

Python

TensorFlow

Keras

LSTM

NAB Dataset